

# SAM

Nguyễn Hoàng Nguyên

## I. Summary

### 1 SAM architecture

Segment Anything Model (SAM) là mô hình segmentation tổng quát, được thiết kế để:

- Encode ảnh một lần
- Segment nhiều lần với các prompt khác nhau
- Hỗ trợ tương tác: point, box, mask

Kiến trúc chính gồm 3 phần:

- Image Encoder
- Prompt Encoder
- Mask Decoder

#### 1.1 Image Encoder (ViT)

- Meta pretrain Image Encoder (ViT) bằng MAE trên dataset ảnh cực lớn (không nhãn)
- Sau đó bỏ decoder của MAE, lấy encoder weights, dùng encoder đó làm backbone để huấn luyện SAM
- Chỉ cần chạy 1 lần cho mỗi ảnh (rất quan trọng cho hiệu năng)
- Output của Image Encoder là image token embedding

\* MAE (Mask AutoEncoder): một kiến trúc thuộc self-supervised learning, kết hợp với ViT che (mask) đi phần lớn dữ liệu đầu vào (Mask ngẫu nhiên  $\sim 75\%$  patches mỗi image và chỉ nhìn thấy 25% còn lại), rồi bắt mô hình tự học cách khôi phục lại phần bị che.

#### 1.2 Prompt Encoder

- Mã hoá tín hiệu điều kiện từ người dùng
- Hướng mô hình tập trung vào vùng mong muốn
- Embedding cùng không gian với image embedding.
- Output của Prompt Encoder là prompt token embedding

### 1.2.1 Point/Box Prompt

**Point Prompt** Mỗi point gồm:

- $(x, y)$  : tọa độ trong ảnh (đã normalize)
- label:
  - $+1 \rightarrow$  positive point (thuộc object output mask)
  - $-1 \rightarrow$  negative point (không thuộc object output mask)

**Box Prompt.** Box được biểu diễn bằng 2 điểm:

- $(x1, y1) = \text{top-left}$
- $(x2, y2) = \text{bottom-right}$

**Positional Encoding.** SAM dùng Random Fourier Features để encode tọa độ point/box, đầu ra là positional embedding

**Type Encoding.** Type embedding trong SAM là các vector học được (learnable embeddings) của point/box prompt (positive/negative, top-left/bottom-right)

**Output.** Output của point/box prompt encoding là tổng của positional embedding và Type Encoding ( $PE + TE$ )

### 1.2.2 Mask Prompt

- Dùng convolution để embedding được mask embedding
- Mask embedding cộng trực tiếp vào image embedding

### 1.2.3 Text Prompt

SAM không có text prompt nhưng trong paper có đề xuất ý tưởng sử dụng model như CLIP để đưa ra embedding là tương quan giữa text-image rồi mới dùng SAM để đưa ra mask tương ứng với text prompt. Thực tế trong source code SAM, SAM2 không có implement với text prompt.

\* CLIP (Contrastive Language–Image Pretraining): là mô hình học liên kết giữa hình ảnh và ngôn ngữ thông qua contrastive learning.

## 1.3 Mask Decoder

- Sử dụng transformer block
- Kết hợp (concatenate) image token embedding và prompt token embedding sau đó thông qua linear projection được vector  $K, V$
- khởi tạo Learnables Token (3 mask tokens và 1 IoU token) thông qua linear projection được vectors  $Q$

- 3 mask tokens: trọng số học trong quá trình training thể hiện đặc trưng của các predict masks đầu ra
- 1 IoU token: trọng số học trong quá trình training, sau khi qua MLP sẽ ra score của các predict masks. Tiêu chí chọn pred mask có score cao nhất, nếu không thì đưa cả 3 pred masks cho user chọn.
- Cross-attention (Q, K, V): giữa (mask tokens + IoU token) với (image token + prompt token)
- Output là 3 context vectors (bằng số lượng mask tokens)

## 1.4 Feature maps

- Khôi phục cấu trúc không gian của image embedding (reshape image embedding)
- Dùng convolution để upsampling được các feature maps
- Feature maps này được dùng để sinh mask dự đoán.

## 1.5 SAM output

- Dùng 3 context vectors ở bước Mask Decoder thông qua MLP để được 3 vectors trọng số ứng với mỗi pred masks (số chiều bằng với số feature map của image embedding)
- Dot product từng vector trọng số này với feature map của image embedding sẽ được tensor có shape HxW
- Như vậy đầu ra là 3 tensor (HxW)
- Thông qua IoU token score (IoU token  $\rightarrow$  MLP  $\rightarrow$  IoU score) đưa ra pred mask có score cao nhất.

## 2 SAM-2 architecture

Segment Anything Model 2 (SAM2) là mô hình segmentation tổng quát cho ảnh đơn và video, mở rộng SAM gốc bằng cách bổ sung hierarchical image encoder và object-centric memory, được thiết kế để:

- Encode ảnh một lần
- Segment nhiều lần với các prompt khác nhau
- Theo dõi object xuyên thời gian trong video
- Hỗ trợ tương tác: point, box, mask

Kiến trúc chính gồm 6 phần:

- Image Encoder (Hiera)
- Memory Attention
- Prompt Encoder
- Mask Decoder
- Memory Encoder
- Memory Bank

### 2.1 Image Encoder (Hiera)

- Không giống như SAM sử dụng kiến trúc ViT để encode, SAM2 sử dụng kiến trúc Hiera kết hợp pretrain bằng MAE làm backbone để encode image.
- Kiến trúc Hiera:
  - Hiera là Hierarchical Vision Transformer, một dạng của kiến trúc Hierarchical.
  - Ảnh đầu vào được ánh xạ sang không gian đặc trưng (feature map) bằng một lớp convolution với kernel và stride  $4 \times 4$ , tạo ra một lưới token có kích thước  $H \times W \times C$ . Mỗi token ban đầu đại diện cho một vùng  $4 \times 4$  pixel của ảnh gốc.
  - Các token được xử lý qua nhiều stage liên tiếp. Mỗi stage bao gồm các Transformer block thực hiện self-attention toàn cục và MLP, trong đó các token luôn gắn với vị trí không gian tương ứng.
  - Giữa các stage, Hiera sử dụng *Q-pooling* để giảm độ phân giải không gian ( $H \times W$ ) trong khi vẫn bảo toàn ngữ cảnh toàn cục thông qua cơ chế attention. Việc này giúp mở rộng receptive field của mỗi token và xây dựng biểu diễn phân cấp theo tỉ lệ.
- Hiera có 4 stage, đầu ra của mỗi stage là một tập các feature tokens có thể được reshape về dạng feature map kích thước  $H \times W \times C$ :
  - Stage 3, 4: dùng cho phần memory (Memory Attention, Memory encoder)
  - Stage 1, 2: dùng cho chi tiết mask (Mask decoder)

## 2.2 Memory Attention

- Memory Attention trong SAM2 thực hiện cross-attention giữa feature tokens của frame hiện tại (Q) và memory token của các frame trước đó được lưu trong memory bank ( $K_{mem}, V_{mem}$ ), được tạo thông qua linear projection, nhằm truyền thông tin object và đảm bảo tính nhất quán theo thời gian.
- feature tokens của frame hiện tại được lấy từ output của stage3/4 của Hiera

Cơ chế này cho phép truyền thông tin object-centric từ quá khứ sang frame hiện tại, đảm bảo tính nhất quán theo thời gian trong video.

## 2.3 Prompt Encoder

- Giống SAM-1

## 2.4 Mask Decoder

- Giống SAM-1 nhưng input đầu vào là concat giữa output của memory attention với prompt token

### 2.4.1 SAM-2 Output

- Giống SAM-1 nhưng feature map được lấy từ output stage1/2 của Hiera

## 2.5 Memory Encoder

Memory encoder biến “kết quả segmentation của một frame” thành các memory tokens có thể lưu trữ (Memory bank) và truy xuất (Memory attention). Ở frame hiện tại, sau khi mask đã được dự đoán, Memory encoder nhận input:

- ObjectRegionFeature: là kết quả element-wise giữa features map ở stage3/4 của Hiera và predict mask
- MaskEmbedding: sau khi có predict mask, mask này sẽ được embedding
- ObjectIDEmbedding: là id của object cần segment, id sẽ được embedding
- FrameEmbedding: là index của frame hiện tại, index này sẽ được embedding

Các thành phần trên sau đó sẽ được concat lại và thông qua linear để embedding tạo thành memory token của frame hiện tại, memory token này sẽ được lưu vào memory bank.

## 2.6 Memory Bank

- Memory bank là một tập (buffer) lưu các memory tokens của nhiều frame trong quá khứ.
- Đến khi segment frame tiếp theo thì các memory tokens này sẽ được truy xuất và thông qua linear tạo  $K_{mem}, V_{mem}$  để cross-attention ở Memory Attention.

### 3 MedSam architecture

- MedSAM là một phiên bản adaptation của SAM được fine-tune và huấn luyện lại để hoạt động hiệu quả riêng ở domain hình ảnh y tế (medical images)
- Cơ sở là kiến trúc của SAM, nhưng được huấn luyện trên tập dữ liệu y tế lớn (hơn 1.5 triệu cặp ảnh-mask) chứa nhiều loại hình ảnh y tế: MRI, CT, X-ray, nội soi, v.v.